

摘要

猕猴前下颞叶皮层（Anterior Inferior Temporal Cortex, AIT）是高级视觉信息处理的核心区域。本实验室前期利用高通量电生理记录，在该区域内发现了大量此前未被充分观测的高度稀疏神经元。然而，这种高度稀疏的表征机制也带来了全新的计算建模困境，导致现有深度神经网络（Deep Neural Network, DNN）无法对其响应进行准确预测。为了探明这一困境究竟是由于 DNN 特征空间本身的表征局限（模型问题），还是因为传统随机盲测无法在大规模自然图库中有效捕获关键激活图像（采样问题），本文旨在探究并引入针对此类稀疏编码的主动采样策略，以期为闭环电生理实验提供理论支撑与工程方案。

考虑到真实动物实验的成本与限制，针对 AIT 区神经元高度稀疏的表征特性，本文构建了一种基于最大熵原理（Maximum Entropy Principle, MEP）的虚拟神经元生成框架。该框架在不引入额外微观机制假设的前提下，通过多目标梯度优化（涵盖稀疏度分布约束、有效维度约束及响应去相关性等），基于预训练模型提取的高维特征，高保真地还原了真实 AIT 神经元的群体统计特征，为采样策略的评估提供了一个具备高度生物合理性的虚拟环境。

在主动采样算法的设计环节，针对高度稀疏神经元引发的预测模型均值塌陷（mean collapse）现象与采样效率瓶颈，本文在全流程图形处理器（Graphics Processing Unit, GPU）加速的主动采样系统下，设计并评估了多种主动采样策略。除引入 Global Greedy 策略进行特征空间的广度探索外，本文原创提出了均值塌陷逃逸采样（Mean Collapse Escape Sampling, MCES）。通过均值偏离，MCES 策略有效引导预测模型避开零响应区域的探索盲区。

此外，考虑到单一策略的不稳定性，本文将主动采样过程建模为马尔可夫决策过程（Markov Decision Process, MDP），并利用强化学习（Reinforcement Learning, RL）训练智能体进行自适应的策略调度。实验结果表明，RL 元策略能够根据特征空间的探索状态动态切换最优采样策略，有效规避了被动随机采样的观测偏误，并确立了当前线性读出架构的经验上确界。本研究不仅为解决稀疏编码下的采样瓶颈提供了一套可行的主动采样方案，也为后续闭环电生理实验的在线部署以及高级视觉皮层编码特性的计算建模提供了有益的方法学参考。

关键词：前下颞叶皮层；主动采样；稀疏编码；强化学习；GPU 加速

Simulated Generation of Sparse Encoding in the Macaque Inferior Temporal Cortex and Active Learning Sampling Strategies

Yao Lu (Biological Science)

Directed by Shiming Tang

ABSTRACT

The macaque anterior inferior temporal (AIT) cortex serves as the central hub for high-level visual information processing. Recent high-throughput electrophysiological recordings have uncovered a substantial population of AIT neurons exhibiting extreme sparsity, a phenomenon previously under-observed. This extreme sparse encoding mechanism introduces a fundamental computational modeling dilemma, severely compromising the predictive accuracy of mainstream deep neural networks (DNNs). It remains unresolved whether this fitting failure originates from the representational limitations inherent in DNN feature spaces (the model problem) or from the extreme inefficiency of passive random sampling in capturing critical activating images from massive natural datasets (the sampling problem). To disentangle this bottleneck, active sampling strategies specifically optimized for such sparse encoding are developed and evaluated, aiming to establish a robust theoretical foundation and engineering pipeline for future closed-loop *in vivo* experiments.

Given the prohibitive costs and physical constraints of *in vivo* animal studies, a virtual neuron generation framework rooted in the maximum entropy principle (MEP) is constructed to proxy the highly sparse AIT responses. Bypassing subjective assumptions regarding micro-circuitry, this framework extracts high-dimensional features from pre-trained visual models and executes multi-objective gradient optimization. By strictly enforcing macroscopic constraints on sparsity distribution, Effective Dimension, and response decorrelation, the algorithm faithfully reconstructs the population statistical properties of real AIT neurons, providing a highly biologically plausible digital testbed for algorithm evaluation.

A major computational challenge in sampling highly sparse targets is the "mean collapse" phenomenon, wherein surrogate models degenerate into predicting uniform zero responses. Operating within a fully GPU-accelerated active sampling system, multiple active exploration strategies are evaluated. Alongside the implementation of the Global Greedy strategy for broad feature space exploration, Mean Collapse Escape Sampling (MCES) is formally proposed. By leveraging a mean deviation penalty, MCES forcefully steers the predictive model away from zero-response exploration dead zones.

Relying on a single, rigid strategy throughout the dynamic sampling process proves inherently unstable. Consequently, the entire active sampling procedure is formulated as a Markov Decision Process (MDP), and a Reinforcement Learning (RL) agent is trained to execute adaptive strategy scheduling. Quantitative results confirm that the RL meta-policy dynamically switches to the optimal sampling algorithm based on the real-time exploration state of the feature space. This adaptive mechanism effectively rectifies the observation bias inherent in passive random sampling and strictly maps out the empirical upper bound of current linear readout architectures. Ultimately, this framework resolves the data acquisition bottleneck associated with sparse encoding, offering critical methodological references for the online deployment of closed-loop electrophysiological systems and the advanced computational modeling of high-level visual cortices.

KEY WORDS: Anterior Inferior Temporal Cortex; Active Learning; Sparse Encoding; Reinforcement Learning; GPU Acceleration

目录

ABSTRACT	II
第一章 引言	1
1.1 灵长类视觉信息的层级处理	1
1.1.1 腹侧视觉通路的层级递进	1
1.1.2 传统视觉神经编码研究与局限	2
1.2 基于人工智能的神经编码模型：范式变革与理论框架	3
1.3 AIT 区稀疏编码的建模困境	4
1.4 主动采样在神经科学中的应用	5
1.5 现有局限与本文创新	6
1.5.1 现有研究的局限性	6
1.5.2 本文的主要工作与创新点	7
第二章 实验材料和方法	8
2.1 实验材料	8
2.1.1 硬件	8
2.1.2 操作系统与软件环境	8
2.2 实验方法	8
2.2.1 虚拟环境构建	8
2.2.1.1 图像数据集与预处理	8
2.2.1.2 深度特征编码与降维	9
2.2.1.3 虚拟稀疏神经元模块	10
2.2.1.4 主动采样预测器读出层	12
2.2.2 主动采样策略设计与评估	13
2.2.2.1 主动采样闭环实验流程	13
2.2.2.2 主动采样的数学框架	14
2.2.2.3 基线策略：随机采样	16
2.2.2.4 基于线性读出层的主动采样策略	16
2.2.2.5 各类主动采样策略比较总结	17
第三章 实验结果	19
3.1 虚拟 AIT 稀疏神经元的生物合理性评估	19
3.1.1 单个神经元响应分布的微观比对	19
3.1.2 神经元群体的特征空间拓扑与去相关性	19
3.1.3 稀疏度分布的宏观对齐与统计检验	20

3.2 主动采样策略在虚拟 AIT 稀疏神经元上的表现.....	21
3.2.1 主动采样显著提升神经响应预测准确度	21
3.2.2 预测性能与绝对误差的背离：均值塌陷的启示	23
3.2.3 MCES 策略对稀疏响应分布的探索机制	24
3.3 通过强化学习优化主动采样策略	27
3.3.1 MDP 建模与状态空间设计.....	28
3.3.2 奖励函数与折扣因子	28
3.3.3 两阶段学习策略	29
3.3.4 强化学习确立主动采样的最优包络面	29
3.3.5 强化学习揭示主动采样的动态策略演化	30
第四章 讨论	33
4.1 实验结论总结	33
4.2 模拟-现实差距分析	33
4.3 未来展望	34
4.3.1 活体闭环电生理实验的部署与闭环微调	34
4.3.2 在线采样系统尝试与优化	34
4.3.3 检索式采样与生成式采样的融合	35
参考文献.....	36
附录 A.....	38
致谢.....	错误!未定义书签。
北京大学学位论文原创性声明和使用授权说明.....	错误!未定义书签。

主要符号和缩写对照表

缩略词	英文全称	中文全称
AIT	Anterior Inferior Temporal Cortex	前下颞叶皮层
IT	Inferior Temporal Cortex	下颞叶皮层
LGN	Lateral Geniculate Nucleus	外侧膝状体
SUA	Single-unit activity	单神经元活动
MUA	Multi-unit activity	多神经元活动
DNN	Deep Neural Network	深度神经网络
DCNN	Deep Convolutional Neural Network	深度卷积神经网络
ViT	Vision Transformer	视觉 Transformer
MAE	Masked Autoencoder	掩码自编码器
RL	Reinforcement Learning	强化学习
MDP	Markov Decision Process	马尔可夫决策过程
DQN	Deep Q-Network	深度 Q 网络
PPO	Proximal Policy Optimization	近端策略优化
MCES	Mean Collapse Escape Sampling	均值塌陷逃逸采样
PCA	Principal Component Analysis	主成分分析
MEP	Maximum Entropy Principle	最大熵原理
KDE	Kernel Density Estimation	核密度估计
GLM	Generalized Linear Model	广义线性模型
CDF	Cumulative Distribution Function	累积分布函数
GPU	Graphics Processing Unit	图形处理器
GAN	Generative Adversarial Network	生成对抗网络
CPU	Central Processing Unit	中央处理器

第一章 引言

1.1 灵长类视觉信息的层级处理

灵长类动物是高度视觉依赖的物种，视觉系统占据了大脑皮层约三分之一的区域，并且具有高度精密且复杂的层级化处理机制¹。

1.1.1 腹侧视觉通路的层级递进

视觉信号经由视网膜与外侧膝状体（Lateral Geniculate Nucleus, LGN）的初步提取与中继反馈²，抵达初级视皮层（V1）。V1 区神经元通过经典的朝向选择性（Hubel & Wiesel, 1968）³，奠定了大脑分析形状的基础。此后，视觉处理分化为两条平行通路（图 1.1）⁴：一条是处理空间与运动信息的背侧通路；另一条则是本研究聚焦的腹侧通路（图 1.2）。腹侧通路专门负责形状、颜色及纹理等特征，是实现物体识别与语义认知的核心路径。

腹侧通路呈现显著的等级化递进结构。视觉信息沿 V1、V2、V4 逐级传至下颞叶皮层（IT）的过程中，神经元感受野持续扩大。V2 与 V4 区逐步完成了从简单纹理到复杂几何（如曲率、角度）⁶ 及表面属性（颜色、明暗对比）⁷ 的特征整合。作为通路的最高级中枢，IT 皮层（尤其是前部的 AIT 区）实现了从“局部特征”到“语义概念”的表征飞跃。经典电生理研究表明，AIT 神经元不再响应简单形状，而是对极其复杂的视觉模式（如特定的面孔、物体类别）表现出高度特异的选择性（Tanaka, 1996）⁸，其内部甚至演化出专门的功能柱与面孔斑结构⁹。更为关键的是，AIT 神经元具备“视觉不变性”¹⁰，即在目标发生平移、缩放、旋转或光照改变时仍能维持稳定的放电率，从而赋予了灵长类在复杂多变的自然环境中稳定识别物体的能力。




图 1.1 灵长类视觉通路的解剖结构与双流假说示意图。展示了视觉信息从视网膜出发，经 LGN 到达 V1，并进一步分化为两条平行处理通路的解剖路径：背侧通路（蓝色箭头）：主要由视网膜的大细胞（Magno）通路驱动，经 V1、V2 投射至 MT 区及顶叶，主要负责处理运动方向和深度信息。腹侧通路（红色箭头）：主要由视网膜的小细胞（Parvo）通路驱动，经 V1、V2 投射至 V4 区及颞叶，主要负责处理颜色和物体形状信息。图中右侧细节展示了不同视觉特征（如颜色、方向、深度）在 V1 和 V2 内部（如斑块、条纹结构）的分离处理机制。图引自 *Principles of neural science*⁵。




图 1.2 腹侧视觉通路与物体识别的层级处理。A-B. 猕猴大脑侧面和腹面的解剖视图，高亮显示了参与物体识别的关键脑区（V1, V2, V4, TEO, IT）。C. 腹侧通路的信息流向示意图。视觉信息呈现出明显的层级传递特征，依次经过 V1→V2→V4→TEO，最终抵达 IT。IT 区是腹侧通路的终端，负责形成复杂的物体表征，并进一步与海马体等记忆系统连接。图引自 *Principles of neural science*⁵。

1.1.2 传统视觉神经编码研究与局限

解构腹侧通路如何从自然图像中提取关键特征，尤其是高级视皮层对自然场景的稀疏编码机制，是当前视觉神经科学的核心命题之一。然而，随着层级的逐渐加深，特征复杂度迅速增长。传统的线性感受野模型（如用于表征 V1 区神经元特征的 Gabor 滤波器）虽能有效描述早期视觉，但在面对中高级视皮层（如 V4、IT）强烈的非线性叠加与广阔感受野时则完全失效。

长期以来，为定量分析高级皮层的复杂响应，早期研究高度依赖基于人类直觉的“特征简化”或低维“参数化刺激”（如提取面孔几何参数）来探索神经元偏好^{10,11}。这种基于主观定义的特征空间在自然场景无穷尽的模式组合面前显得捉襟见肘，根本无法有效覆盖高级

神经元真实的特征选择性。特别是在腹侧通路终端的 AIT 区，神经元直接参与高度抽象的“物体身份”编码。全尺寸自然图像所引发的“维度灾难”，使得传统的静态实验设计与经典建模范式难以为继。因此，为了准确阐明以 AIT 区为核心的非线性计算机制，视觉神经科学亟需引入表征能力更强的数学建模语言。

1.2 基于人工智能的神经编码模型：范式变革与理论框架

过去十年来，视觉神经科学逐步确立了“任务驱动（Goal-Driven）”建模范式（Yamins & DiCarlo, 2014）¹²。研究证实，无需刻意模拟底层生物学细节，仅依靠反向传播优化深度神经网络（DNN）的图像分类性能，即可促使其内部特征自发对齐灵长类腹侧视觉通路神经元的编码特性。这种对齐呈现出严格的对应关系（图 1.4）：网络的浅、中、深层特征可分别高精度线性映射 V1、V4 及 IT 区神经元的响应规律¹³。DNN 因此可以成为刻画 AIT 区复杂语义表征的有效计算基底。

随后，人工智能模型对生物视觉的拟合边界被不断拓宽。例如，深层残差网络与循环连接的引入，成功解析了 IT 神经元的晚期反馈机制（Kar 等, 2019）¹⁴。而在脱离人工标签的条件下，基于对比学习的自监督模型（如 SimCLR、MoCo）同样涌现出了高度类脑的视觉表征，且更契合自然生物的无监督学习机制（Zhuang 等, 2021）¹⁵。以上大量的工作促成了“神经连接主义”框架的成型（Doerig 等, 2023）¹⁶。经过大规模训练的人工神经网络，开始作为生物视觉的“计算代理”，被广泛应用于定量解析高级视觉皮层的计算规律。




图 1.4 任务驱动的深度卷积神经网络（Deep Convolutional Neural Network, DCNN）与灵长类腹侧视觉通路的层级对应关系。A. 猕猴大脑腹侧视觉通路的解剖结构示意图，展示了从 V1 区到 AIT 区的逐级处理流。B. 生物视觉系统的层级处理模型，涵盖从视网膜神经节细胞（RGC）、LGN 区到 IT 区的信息传递过程。C. DCNN（HMO 模型）的架构示意，包含卷积、阈值化、池化和归一化等计算操作。绿色虚线箭头揭示了人工神经网络与生物视觉系统之间的层级映射关系：DCNN 的浅

层、中层和深层单元的内部表征，能够分别以线性方式较高精度地预测生物视觉通路中 V1 区、V4 区和 IT 区神经元的反应。这一发现证明了针对物体分类任务训练的 DCNN 能够作为灵长类视觉系统的有效预测模型。图引自 Yamins (2016)¹³。

1.3 AIT 区稀疏编码的建模困境

灵长类视觉系统是为处理自然场景而演化的，因此作为构建上述映射模型、标定神经编码机制的核心测试媒介，自然图像无疑是不可或缺的。然而，自然图像潜在的模式空间几乎是无限的，这与有限的实验样本之间存在着巨大的矛盾。

在低级视觉皮层（如 V1）的研究中，研究者通常采用一种“空间降维”的策略来提高采样效率：即先测定神经元微小的感受野范围，然后将刺激图片限制在感受野内，从而大幅减少需要测试的像素维度。

然而，这一策略在 AIT 区脑区难以奏效。与 V1 区神经元不同，AIT 区神经元通常具有覆盖几乎整个中央视野的超大感受野¹⁷。这意味着无法通过限定空间位置来缩小搜索范围，必须在全尺寸的自然图像空间中寻找有效刺激。这种无法规避的高维特性，使得在 AIT 区进行自然场景编码研究面临着严峻的高维搜索困境。

理论上的建模困境在真实的电生理实验中得到了确凿的数据印证。近年来，随着高通量电生理技术的发展，本实验室率先利用 Neuropixels 2.0 探针在猕猴 AIT 区进行了大规模的单神经元活动（Single-unit activity, SUA）记录（图 1.5）。为最大限度地覆盖广阔的自然视觉特征空间，本研究采用了被动随机采样与定向精选相结合的策略。实验从包含 1 万张自然图像的 ImageNet 子集中，随机抽取 2000 张并人工精选 1000 张，共同构成了 3000 张图像的视觉刺激集，用于对猕猴进行测试。

真实的结果揭示，AIT 区并非由同质化的神经元组成，而是展现出了极具异质性的编码策略。具体而言，研究发现单神经元活动整体上表现出极高的稀疏性（Sparsity）（定义见附录 A.1）——神经元群体中既存在对多种刺激广泛响应的神经元，也包含大量仅对极少数特定图像产生强烈响应的稀疏神经元（Sparse neurons, S）。

这种高度的稀疏编码特性直接带来了建模上的困难。数据表明，随着神经元稀疏度的升高，DNN 对其响应的预测性能呈现出显著下降。面对这些仅对极少数图像产生响应的稀疏神经元，现有的 DNN 模型几乎完全无法拟合其神经响应。

然而，一个根本性的问题尚未得到解答：这种预测性能的显著下降究竟是源于预测模型架构本身的局限性，还是由于随机采样未能提供足够覆盖神经元响应分布的训练样本？换句话说，无法确定这些稀疏神经元的建模困境是因为它们具有现有 DNN 无法捕捉的复杂表征，还是仅仅因为没有找到那些能够激活它们的关键图像。

如果后一种假设成立——即稀疏神经元对自然图像中某些罕见特征组合具有高度特异性反应，而有限的随机样本极大概率无法激活其狭窄的偏好空间——那么传统的随机采样策略将直接导致观测偏误，使得模型在标定神经元真实偏好时产生严重偏差。

为了验证这一假设，并彻底打破由被动采样带来的认知盲区，研究中亟需引入能够在高维空间中进行自适应探索、主动探索并逼近神经元潜在偏好的主动采样策略（Active Learning Sampling）。这不仅是提升模型拟合率的技术改进，更是精确解构高级视觉皮层稀疏编码机制、建立可靠神经映射模型不可或缺的探索范式。




图 1.5 猕猴 AIT 区大规模单神经元记录范式与稀疏编码困境。 A. 实验记录范式：利用 Neuropixels 2.0 探针，在视觉刺激流下对猕猴 AIT 区进行大规模 SUA 记录；刺激集构建：从 10000 张候选图像中，结合被动随机采样（2000 张）与基于先验特征的人工精选（1000 张），构建总计 3000 张的测试刺激集。 B. 稀疏特性与预测瓶颈：对比了广泛调谐神经元与稀疏神经元（S 群体）在放电模式上的显著差异。上述工作主要由鲁奇、熊心怡完成。

1.4 主动采样在神经科学中的应用

主动采样的概念最早脱胎于统计学中的最优实验设计（Optimal Experimental Design）以及机器学习领域，其核心思想是由算法主动挑选最具信息量的样本进行测试，从而以最少的数据量加速模型的收敛。在感觉系统神经科学中，将该思想应用于活体实验的最早尝试之一是 Peter Földiák¹⁸ 等人在 2001 年开展的开创性工作，他们率先展示了如何利用闭环系统快速搜索并识别初级视觉皮层（V1）神经元的偏好刺激。随后，Lewi 等人（2009）¹⁹ 取得了重要突破，针对传统高维神经元系统实时计算的瓶颈，提出了一种用于神经生理学实验序列最优设计的快速算法，该算法通过最大化数据与广义线性模型（GLM）未知参数之间的互信息，在闭环中实时挑选最具信息量的刺激。DiMattina 与 Zhang²⁰ 系统性地总结了这些自适应刺激优化算法，将其划分为三大核心实验范式：寻找最大化响应的最优刺激、寻找等响应刺激集合，以及用于模型参数估计的系统辨识。

随着 DNN 成为视觉皮层建模的主流工具，模型参数量呈指数级增长，当代神经科学中的主动采样策略也根据刺激的连续性逐渐演化为两大主要技术路线：刺激检索（Stimulus Retrieval）与刺激合成（Stimulus Synthesis）。

刺激检索是指从一个预先构建的、规模极其庞大的候选刺激库（如海量自然图像数据

集)中,通过主动采样算法自适应地筛选出对当前模型优化最有利的一小批刺激进行展示。近年来的前沿研究在此领域取得了显著的进展。例如, Cowley 等人(2022)²¹提出了名为“Adept”的自适应刺激选择框架,打破了传统主动采样仅关注单个神经元响应最大化的局限,转而优化整个记录到的神经元群体的响应目标函数。这种交替进行数据收集与模型训练的闭环检索范式,成功为灵长类 V4 皮层构建了具有高预测精度的 DNN 模型,并启发了后续通过模型压缩技术(将 6000 万参数压缩数千倍)揭示早期视觉处理共享滤波器等计算基序的研究²²。此外,针对自然图像特征分布的局限性, Cowley 等人(2020)²³发现如果在检索图像库中引入高对比度二值化图像进行筛选,由于这类图像过分强调了自然图像中最有助于高效训练 DNN 的底层特征,其在训练数据极少情况下的表现甚至优于传统的自然图像主动采样策略。

与检索法受限于现有刺激库的分布不同,刺激合成法则利用生成式模型,通过优化算法生成全新刺激。在自适应图像刺激优化的范畴内,这种方法通常依赖于计算当前模型响应相对于刺激图像空间的梯度,并沿着梯度上升的方向进行迭代,从而合成出理论上能够最大化神经元响应或提供最大模型信息熵的极端图像。相比于刺激检索,刺激合成能够探索理论上无限的视觉连续空间。

综上所述,无论是通过对自然图库进行高效筛选的刺激检索法,还是在连续特征空间中进行探索的刺激合成法,闭环主动采样策略均为解决高级视觉皮层复杂神经编码模型所面临的样本量瓶颈提供了关键的技术手段。本研究主要采用基于自然图库的刺激检索方法,聚焦于猕猴 AIT 区稀疏编码的生物学特性,系统探讨并模拟评估适用于该脑区的高效主动采样策略。

1.5 现有局限与本文创新

1.5.1 现有研究的局限性

尽管主动采样技术在神经科学中的应用日益增多,但当研究视野推进至高级视觉皮层(如 AIT 区)时,一个核心的科学问题尚未得到系统解答:在面对高度稀疏的神经编码时,主动采样能否有效破解“模型拟合失效”与“数据采样不足”相互纠缠的认知困境?深入审视现有的基于自然图库的主动采样研究,其在应对此类高度稀疏表征时仍暴露出以下两大局限:

第一,现有采样策略在稀疏响应分布下的适用性与评估基准尚不完善。当前的主动采样策略大多基于具有相对连续特征调谐特性的视觉神经元(如早期和中级视皮层)进行设计与验证。面对 AIT 区具有高度稀疏性的神经元,传统策略能否在庞大的自然图像特征空间中稳定地寻找到神经元的偏好刺激,尚缺乏系统的评估。此类神经元的窄调谐特性往往导致预测模型在初始采样阶段面临海量的零响应反馈,极易引发预测分布的均值塌陷与同

质化。所谓均值塌陷，是指由于训练数据被海量零响应样本主导，模型为最小化全局均方误差（MSE）而倾向于将所有预测值收缩至接近零的全局均值，从而丧失了刻画神经元选择性响应趋势的能力。

第二，单一固定的采样策略难以适应动态探索需求。现有的主动采样策略通常依赖于单一的启发式规则。然而，在大规模图库中检索高度稀疏的神经特征是一个高度动态的过程。在主动采样的不同迭代阶段，预测模型对探索与利用的权衡需求存在显著动态变化。单一固定的采样策略无法感知特征空间的演化状态并进行自适应调整，这在很大程度上限制了模型逼近神经预测性能上限的潜力。

1.5.2 本文的主要工作与创新点

针对上述局限，本研究融合计算机视觉与计算神经科学，主要工作与创新点如下：

第一，构建了基于最大熵原理的虚拟 AIT 稀疏神经元。针对活体实验变量较难控制的问题，本研究构建了一个高度拟真的虚拟 AIT 区神经元评估环境。在不引入额外微观机制假设的前提下，通过多目标梯度优化（涵盖稀疏度分布对齐、群体有效维度约束以及显式的特征去相关性），在深度特征空间中精确复现了真实猕猴 AIT 区神经元群体的统计学先验。该客观还原了 AIT 区神经元稀疏的响应景观，为量化评估主动采样策略提供了一个具备严格生物学约束的基准平台。

第二，设计并验证了针对稀疏神经元的双重主动采样改进策略。针对 AIT 区稀疏神经元在初始采样阶段易导致预测模型陷入均值塌陷的问题，本文在全流程 GPU 加速的主动采样系统下，不仅引入 Global Greedy 策略进行特征空间的广度探索，更原创提出了 MCES 策略。通过均值偏离机制，成功引导预测模型有效规避了零响应区域的探索盲区，显著提升了模型对长尾罕见特征的检索与拟合效率。

第三，提出了基于强化学习的主动采样自适应调度框架（元策略）。鉴于单一固定的采样准则难以适应稀疏神经编码在不同阶段的探索需求，本研究将主动采样过程建模为马尔可夫决策过程（Markov Decision Process, MDP），并利用强化学习训练智能体。实验结果表明，该元策略（Meta-Policy）能够根据当前特征空间的演化状态，动态且自适应地切换最优采样策略。这一框架有效规避了被动随机采样的观测偏误，并探明了当前线性读出架构的经验上确界，为闭环神经电生理实验提供了一套兼具鲁棒性与数据效率的系统级方案。

第二章 实验材料和方法

2.1 实验材料

本研究仅包含理论分析与代码实验，均在基于 Linux 操作系统的云端计算服务器上完成。

2.1.1 硬件

图形处理器（Graphics Processing Unit, GPU）：单张 NVIDIA GeForce RTX 5090，配备 32 GB 显存。

中央处理器（Central Processing Unit, CPU）：25 核心 Intel(R) Xeon(R) Platinum 8470Q 处理器。

系统内存：90 GB。

2.1.2 操作系统与软件环境

操作系统：Ubuntu 22.04 LTS。

计算框架：实验的顶层逻辑主要使用 Python 3.12 语言编写。所有深度学习相关的模型构建、读出层的岭回归/梯度更新等，均依托于 PyTorch 2.7.0 深度学习开源框架实现。

并行计算加速：为充分发挥 RTX 5090 的大规模并行计算能力，底层硬件驱动依赖于 NVIDIA CUDA Toolkit 12.8。所有代码均在 CUDA 12.8 环境下进行了底层加速与效能优化。

2.2 实验方法

2.2.1 虚拟评估环境构建

为了在可控、无硬件漂移的环境下验证主动采样策略的有效性并避免大规模计算资源的浪费，本研究参考了 Cowley 等人（2020）²³ 在测试高对比度二值化图像时所采用的“双网络虚拟实验范式（Dual-DNN Virtual Simulation）”（图 2.1）。在此基础上，本研究针对 AIT 复杂的生物学特性进行了深度改造，构建了一个高度拟真的虚拟评估环境。

2.2.1.1 图像数据集与预处理

本虚拟实验的候选刺激池采用 YFCC100M 自然图像数据集的无偏子集（约 100k 张图片，随机分为 80k 训练集，10k 验证集与 10k 测试集）。所有图像均适配标准预处理管线（缩放、中心裁剪、归一化），并根据不同虚拟单元的需求调整输入分辨率（一般 DNN 适配 224×224）。




图 2.1 双网络虚拟实验范式示意图。该实验框架主要由两条平行的信息处理路径构成。下方为基准响应生成路径：输入自然图像被送入充当“虚拟大脑”的神经响应模拟器，以生成目标虚拟神经元的真实响应基准（Ground Truth Responses）。上方为特征编码与预测路径：同一组输入图像首先经过权重冻结的预训练深度神经网络（如 ResNet-50）以提取高维视觉特征，随后输入至由线性回归构成的读出层（Readout Network），产生预测响应（Predicted Responses）。在整个优化与主动采样过程中，预训练模型的参数保持不变，仅对读出层网络进行训练，使其输出不断逼近下方生成的基准响应。该范式使得在纯计算环境中模拟、验证并优化采样策略成为可能。

2.2.1.2 深度特征编码与降维

为使虚拟神经元具有生物学意义的视觉特征表征，本研究依托预训练深度神经网络构建统一的特征编码空间。

第一，特征提取。本研究依托在 ImageNet 上预训练的经典与前沿深度视觉网络作为特征编码器。为使输入特征更贴近灵长类 AIT 区的表征模式，本研究特意提取了各模型特定中间层的输出作为特征空间。具体采用的模型及提取层级包括：ResNet-50 (layer3)、VGG-19 (conv5_4 层)、DenseNet-121 (denseblock3)，以及视觉 Transformer 系列架构的 ViT-Base（第 5 层 encoder layer）、DINOv2-Base（第 8 层 block）和纯视觉掩码自编码器 MAE（第 8 层 block）。这些模型已被证实与灵长类腹侧视觉通路（V4/IT）存在层级对应关系。通过广泛引入上述经学界公认、特征表达能力极强的前沿大模型，本研究在实验设计之初便有效排除了因“底层特征提取能力不足”而导致预测失败的干扰因素。这一设计使得后续实验能够将性能瓶颈精准剥离，纯粹聚焦于“神经元高度稀疏表征”与“主动采样策略效率”之间的核心科学问题。

第二，降维与标准化。针对不同网络架构输出的特征张量，本研究采取了统一的降维聚合策略：对于 CNN 架构输出的四维张量，应用自适应平均池化将其空间维度压缩至 7×7

并进行展平;对于 ViT 等基于自注意力机制的模型,则提取其序列输出中的分类令牌([CLS] Token)。随后,利用训练集数据拟合的标准差缩放器(Standard Scaler)对特征进行中心化与归一化处理,并利用主成分分析(Principal Component Analysis, PCA)将所有特征统一降维至 1000 维。这一降维后的 1000 维特征空间构成了后续生成虚拟稀疏神经元和主动采样策略进行特征检索与价值评估的标准输入空间。

2.2.1.3 虚拟稀疏神经元模块

虚拟 AIT 稀疏神经元表征高度稀疏、特异的物体身份编码。为模拟这一特性,本研究采用最大熵原理(Maximum Entropy Principle, MEP)构建概率生成模型,分别使用 2.2.1.2 节中得到的 PCA 特征作为输入特征各生成 50 个虚拟 AIT 稀疏神经元。

Schneidman 等(2006)²⁴的经典研究表明,在仅约束观测到的统计量(如成对相关性)条件下,选择熵最大的概率分布能够准确预测神经群体的网络状态。本研究将这一原理应用于虚拟 AIT 稀疏神经元的模拟生成,在约束稀疏度分布、有效维度、以及微观响应分布等关键统计量的条件下,选择熵最大的分布,从而在不引入额外假设的前提下最客观地描述神经活动。

在响应生成环节,生成架构采用单层线性读出网络。同时为了准确模拟高度稀疏目标中普遍存在的生物学底噪,网络选用平移指数线性单元(Shifted ELU)作为激活函数,总的前向计算公式如下:

$$z = \text{ELU}(\mathbf{X}_{\text{norm}} \cdot \mathbf{W} + \mathbf{b}, \alpha) + \epsilon$$

其中 $\mathbf{X}_{\text{norm}}$ 为 Z-score 归一化后的输入特征, $\mathbf{W}$ 和 $\mathbf{b}$ 为可学习的权重和偏置。参数 α (本研究设为 0.03) 控制了基线放电强度,使得即使在极负的输入下,神经元响应也能平滑地贴近小量 ϵ , 从而高保真地模拟了真实生物神经元的自发性基线放电。

传统最大熵模型通常采用吉布斯采样从 Boltzmann 分布中抽取样本:

$$P(\mathbf{r}|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} \exp(-E(\mathbf{r}|\mathbf{x}))$$

考虑到该采样方式在高维空间下的收敛效率极低,优化环节转而借助 PyTorch 自动微分与 GPU 并行计算,直接对能量函数 $E(\mathbf{r}|\mathbf{x})$ 执行梯度下降。能量函数包括以下几项约束:

1. 宏观稀疏度

为确保生成的神经群体在稀疏度统计量与真实数据一致,构建稀疏度损失 $\mathcal{L}_S$:

$$\mathcal{L}_S = \frac{1}{N} \sum_{i=1}^N \omega_i (S_i - S_i^*)^2 + \mathcal{L}_{\text{quantiles}}$$

其中 S_i 为当前生成的稀疏度升序序列, S_i^* 为真实神经元稀疏度升序序列, ω_i 为抛物线型权重。此外,进一步引入了对中位数及核心分位数(25%, 75%)的偏离惩罚 $\mathcal{L}_{\text{quantiles}}$, 以进一步约束稀疏度统计量对齐。

2. 有效维度与方差均衡约束

为防止生成架构赋予极少数神经元极大方差，引入有效维度（Effective Dimension，定义见附录 A.1）损失 $\mathcal{L}_{ED}$ 与方差均衡惩罚 $\mathcal{L}_{VB}$ ：

$$\mathcal{L}_{ED} = (ED_{\text{current}} - ED_{\text{target}})^2$$

$$\mathcal{L}_{VB} = \frac{\frac{1}{N} \sum (v_i - \bar{v})^2}{\bar{v}^2 + \epsilon}$$

其中 v_i 为单个神经元响应方差， $\bar{v}$ 为群体方差均值。 $\mathcal{L}_{VB}$ 约束了放电方差差异，确保每个神经元均对整体有效维度做出实质性贡献。

3. 微观响应分布与显式去相关对齐

为防止特征提取过程中的响应重叠并填平非线性截断，本研究直接提取了真实神经元的响应排序曲线作为“绝对靶点”，引入微观响应分布损失 $\mathcal{L}_{\text{curve}}$ ：

$$\mathcal{L}_{\text{curve}} = \frac{1}{M} \sum_{k=1}^M \tau_k (Y_k^{\text{ranked}} - Y_k^{*\text{ranked}})^2$$

通过赋予长尾部分（排序靠后的样本）更大的权重 τ_k ，强迫网络重现真实的平缓长尾衰减。同时，摒弃了简单的非对角线归零策略，引入显式皮尔逊去相关损失 $\mathcal{L}_{DC}$ ：提取相关系数矩阵上三角的非对角元素并进行排序，直接与真实的猴子相关系数累积分布函数（CDF）进行均方误差计算，从而精确复刻了特征空间的独立与正交分布形态。

$$\mathcal{L}_{DC} = \frac{1}{N(N-1)} \sum_{i=1}^N \sum_{\substack{j=1 \\ j \neq i}}^N \rho(r_i, r_j)^2$$

综合上述机制，实践中用于梯度优化的完整能量函数扩展为：

$$E(\mathbf{r}|\mathbf{x}) = \lambda_S \mathcal{L}_S + \lambda_{ED} \mathcal{L}_{ED} + \lambda_{\text{curve}} \mathcal{L}_{\text{curve}} + \lambda_{DC} \mathcal{L}_{DC} + \lambda_{VB} \mathcal{L}_{VB}$$

此外，本研究在生成阶段与评估阶段针对有效维度的计算采取了不同的策略。在训练阶段，为确保梯度稳定，有效维度损失 $\mathcal{L}_{ED}$ 的计算基于全部 50 个神经元的完整响应。而在模型训练完成后的评估阶段，为检验结果的鲁棒性，引入了随机重采样计算其有效维度的统计分布。

在具体实施阶段，本研究采用 AdamW 优化器对上述能量函数进行最小化。经过约 80000 次迭代后，网络参数达到稳定收敛。最终，该生成模型在稀疏度分布、有效维度等核心统计指标上与真实猕猴数据高度吻合，表明本框架能够高保真地复现稀疏神经元群体

的真实编码空间，为后续的主动学习实验提供了一个坚实、可靠的虚拟评估环境。




图 2.2 基于最大熵原理的虚拟 AIT 稀疏神经元生成框架。自然图像经深度特征提取与 PCA 降维后作为输入（步骤 1-2）；生成模型基于最大熵原理构建（步骤 3），通过梯度下降优化最小化复合能量函数。该优化过程严格融合了宏观稀疏度对齐、群体响应去相关、方差均衡等多重统计学约束（步骤 4），最终高保真地重构出符合真实生物学编码特性的虚拟稀疏神经元群体（步骤 5），并与真实 AIT 稀疏神经元进行比较验证（步骤 6）。

2.2.1.4 主动采样预测器读出层

在获取低维稠密特征后，预测器模块需通过读出网络将特征映射为虚拟神经元的基准响应。为全面评估不同计算复杂度下的主动采样表现，本模块主要采用线性读出模块。线性读出网络（Linear Readout）采用带有 L2 正则化惩罚的岭回归（Ridge Regression，本研究中设定正则化系数 $\alpha = 1.0$ ）。该架构计算效率极高、参数解释性强，其特征协方差矩阵的逆矩阵能够为基于几何排斥的主动采样策略（如 Global Greedy 策略）提供闭式解析解，极大加速了候选池的全局打分过程。

2.2.2 主动采样策略设计与评估

在确定了基于“特征编码-线性/浅层读出”的神经响应预测架构后，本节重点阐述如何在大规模自然图库中设计高效的主动采样策略。针对 AIT 区神经元高稀疏的特点，本研究在统一的数学框架下设计并实现了多种经典的与前沿的主动采样策略。为防止模型在早期因稀疏响应陷入局部的采样盲区，所有主动采样策略均引入了混合采样机制，即在每轮选取的样本批次中，保留 50% 的纯随机采样以维持基础的探索能力，剩余 50% 由各主动采样策略进行精选。




图 2.3 批处理主动采样实验流程示意图。初始化阶段（Session 0）：随机采样 1500 张图片构成初始训练集，训练初始预测模型。主动采样迭代（Sessions 1-50）：每轮迭代包含五个步骤——（a）候选池评估与样本选择：基于当前模型 M_{t-1} 选择 250 张图片，另外 250 张随机选择，得到 B_t ；（b）响应观测：获取 B_t 的真实响应；（c）模型更新：在扩展训练集 D_t 上重新训练读出线得到；（d）性能评估：在固定测试集上计算 Pearson r 。迭代持续 50 轮直至完成全部 9000 张图片的采样，输出最终模型与学习曲线。

2.2.2.1 主动采样闭环实验流程

在确立了半随机半主动的混合采样机制后，本节构建了一套统一的批处理闭环实验框架（图 2.2），以此系统量化各策略在虚拟 AIT 稀疏神经元上的探索效率。该流程高度还原了真实活体电生理实验中“训练模型—挑选样本—观测响应—更新权重”的迭代过程（算法 2.1，图 2.3）。

为了确保对比的公平性，所有策略均在相同的实验参数下运行。具体而言，实验的候选图像池由 100000 张经过 2.2.1.2 节特征编码的 YFCC100M 自然图像构成。在初始化阶段（即 Session 0），系统会模拟真实的先验随机采集过程，从中随机抽取 1500 张图像来获取虚拟神经元的基准响应，并训练出初代预测模型 M_0 。

进入正式的主动采样循环后，考虑到真实的动物活体实验往往受限于每日可承受的最大试次，单轮的采样批次被严格限定为 500 张新图像。整个闭环采集将持续迭代 15 轮，对于每一轮迭代 $t = 1, 2, \dots, 15$ ，分别进行：a) 候选池评估与样本选择：在当前模型 M_{t-1} 的预测下，依据具体主动采样策略在未选图池中选择 $N_{\text{sampling}} = 500$ 张图像构成新批次 B_t 。b) 响应观测：获取 B_t 中图像对应的虚拟神经元基准响应，加入训练集： $\mathcal{D}_t \leftarrow \mathcal{D}_{t-1} \cup B_t$ 。c) 模型更新：在 $\mathcal{D}_t$ 上重新训练读出层，得到更新后的模型 M_t 。

在每轮数据收集与模型更新完毕后，系统将计算预测响应与真实值之间的 Pearson 相关系数，从而追踪并记录各采样策略的学习进度。

```

1           输入  $\mathcal{U}$ 
2           输出  $M$ 
3           初始化：
4            $\mathcal{D}_0 \leftarrow \text{Random Sampling 1500 from } \mathcal{U}$ 
5            $M_0 \leftarrow \text{Train}(\mathcal{D}_0)$ 
6           for  $t = 1$  to  $N_{\text{sessions}}$  do
7                $B_t \leftarrow \text{Select 500 from } \mathcal{U}_{t-1}$ 
8                $\mathcal{D}_t \leftarrow \mathcal{D}_{t-1} \cup B_t$ 
9                $M_t \leftarrow \text{Train}(\mathcal{D}_t)$ 
10          end for
    
```

算法 2.1，主动采样闭环伪代码。

为量化不同主动采样策略的采样效率，本研究采用以下核心指标：

学习曲线：绘制预测性能（Pearson r ）随累积样本量（ $N_{\text{initial}} + (k - 1) \times N_{\text{sampling}}$ ）的变化曲线。曲线上升越快，说明采样效率越高。

固定数据预算下的绝对预测性能：提取特定采样迭代节点（例如探索初期、中期及末期）的测试集表现，横向对比不同采样策略所能达到的 Pearson r 分布。该指标配合配对统计检验（如 Wilcoxon 符号秩检验），用于量化在同等样本规模约束下，主动采样策略相对于基线策略在特征拟合精度上的显著性优势与绝对提升量。

2.2.2.2 主动采样的数学框架

假设在某一轮实验中，系统总共记录了 T 个图像样本，目标脑区包含 m 个神经元。设真实的神经元群体响应矩阵为 $\mathbf{Y} \in \mathbb{R}^{T \times m}$ ，预测模型预测的响应矩阵为 $\hat{\mathbf{Y}} \in \mathbb{R}^{T \times m}$ 。为了消除基线发放率的偏差，引入中心化矩阵

$$\mathbf{C} = \mathbf{I} - \frac{1}{T} \mathbf{1} \mathbf{1}^T$$

其中 $\mathbf{I}$ 为单位矩阵, $\mathbf{1}$ 为全 1 向量。利用该矩阵, 第 j 个神经元 (对应矩阵的第 j 列) 的 Pearson r 可简洁地表示为:

$$r_j = \frac{\mathbf{Y}_{:,j}^T \mathbf{C} \hat{\mathbf{Y}}_{:,j}}{\sqrt{\mathbf{Y}_{:,j}^T \mathbf{C} \mathbf{Y}_{:,j}} \sqrt{\hat{\mathbf{Y}}_{:,j}^T \mathbf{C} \hat{\mathbf{Y}}_{:,j}}}$$

在批量主动采样设定中, 假设当前第 t 轮实验已拥有历史数据集 $\mathcal{D}_{t-1}$, 模型在历史数据上训练得到 M_{t-1} , 未标注的候选图像池记为 $\mathcal{U}_t = \mathcal{U} \setminus \mathcal{D}_{t-1}$ 。主动采样策略需要从中挑选一个大小为 N_{sampling} 的新样本集 $\mathcal{B}_t = (\mathbf{X}_t, \mathbf{Y}_t) \subset \mathcal{U}_t$ 。将 $\mathcal{B}_t$ 及其对应的真实响应拼接入全局矩阵后, 主动采样的理想优化目标可形式化为: 寻找最优子集 $\mathcal{B}_t^*$, 使得所有 m 个神经元的相关系数均值最大化, 即:

$$\mathcal{B}_t^* = \arg \max_{\mathcal{B}_t \subset \mathcal{U}_t, |\mathcal{B}_t| = N_{\text{sampling}}} \frac{1}{m} \sum_{j=1}^m r_j (\mathcal{D}_{t-1} \cup \mathcal{B}_t)$$

为了探究如何最大化上述目标, 可以从连续优化的视角分析全局 r 对新输入样本 $\mathbf{X}_t$ 的敏感度。设目标函数为

$$R = \frac{1}{m} \sum r_j$$

根据多元微积分的链式法则, R 对 $\mathbf{X}_t$ 的梯度依赖于真实生物系统 $g(\cdot)$ 与预测模型 M_{t-1} 的雅可比矩阵:

$$\nabla_{\mathbf{X}_t} R = \sum_{j=1}^m \left[\underbrace{\left(\frac{\partial \mathbf{Y}_{t,j}}{\partial \mathbf{X}_t} \right)^T}_{\text{真实系统 } g(\cdot) \text{ 的雅可比}} \nabla_{\mathbf{Y}_t} R + \underbrace{\left(\frac{\partial \hat{\mathbf{Y}}_{t,j}}{\partial \mathbf{X}_t} \right)^T}_{\text{预测模型 } M_{t-1} \text{ 的雅可比}} \nabla_{\mathbf{Y}_t} R \right]$$

然而, 上述严谨的数学推导在将其落地于真实的 AIT 区实验时, 暴露出三个关键的问题:

第一, 真实机制 $g(\cdot)$ 的黑盒特性。在进行电生理测试之前, 真实的神经响应映射 $g(\mathbf{X}_t)$ 及其雅可比矩阵 $\frac{\partial \mathbf{Y}_t}{\partial \mathbf{X}_t}$ 是绝对未知且不可导的。由于无法预知 $\mathbf{Y}_t$, 上述链式法则彻底失效, 导致无法通过直接的梯度上升来优化 Pearson r 。

第二, 离散采样空间的组合爆炸 (NP-Hard 困境)。由于实验刺激必须从给定的海量自然图像图库 $\mathcal{U}_t$ (如 10 万级规模) 中选取, 这是一个纯粹的离散组合优化问题。从库中挑选 N 个样本的组合数高达 $\binom{|\mathcal{U}_t|}{N}$ 。这在计算复杂度上属于典型的 NP-Hard 问题, 在有限的闭环记录窗口内穷举评估所有组合是完全不可能的。

第三, 高维特征下的批量冗余。由于 AIT 区神经元的反应高度稀疏, 如果仅依靠预测模型 M 贪心地挑选预测方差或期望收益最大的前 N_{sampling} 个样本, 这些样本往往会在高

维特征空间的同一个未探索角落高度聚集（扎堆）。这种缺乏多样性的冗余采样不仅浪费了宝贵的电生理记录试次，甚至可能导致更新后的模型发生过拟合。

鉴于直接求解 $\mathcal{B}_t^* = \operatorname{argmax} R$ 在理论上不可计算、在工程上不可穷举，因此必须退而求其次，放弃对真实响应 $\mathbf{Y}_t$ 的依赖，转而利用预测模型 M 在特征空间上的认知不确定性和样本间的几何排斥力来构建可计算的采集函数（Acquisition Function） $a(\mathbf{x})$ 。

在严格的数学定义上，采集函数 $a: \mathcal{U}_t \rightarrow \mathbb{R}$ 是一个从图像（通常使用高维图像特征代替图像本身）映射到实数域的标量效用打分。它的物理意义在于：在当前预测模型状态 M 与已有数据集 $\mathcal{D}_{t-1}$ 的先验下，仅依赖已知的候选样本 $\mathbf{x}$ 与模型的认知盲区，去预估一旦将候选样本 $\mathbf{x}$ 纳入训练集，其对于收敛逼近最优模型参数的期望边际信息增益。在本文的批量采样设定中， $a(\mathbf{x})$ 并非采样概率分布，而是代表决定性的采集优先级——系统将严格依据该得分对候选池进行降序排列或序列贪心提取。

2.2.2.3 基线策略：随机采样

在评估主动采样策略的有效性之前，需要建立合理的数据效率基准。随机采样（Random Sampling）作为最朴素的采样策略，不依赖于任何模型预测或不确定性估计，仅从候选池中均匀随机地选取样本。该策略构成了主动采样策略的基线对照（Baseline），其样本节省率直接反映了主动采样策略相对于“盲目探索”的优越性。

从统计学视角来看，随机采样等价于从总体中进行简单随机抽样（Simple Random Sampling, SRS）。当样本量趋于无穷时，随机采样能够渐进地覆盖整个特征空间，但在有限样本预算下，其数据效率往往远低于自适应采样策略。本研究将随机采样作为所有对比实验的基准，以量化各类主动采样策略的实际加速比。

2.2.2.4 基于线性读出层的主动采样策略

对于岭回归等线性预测器，模型的预测不确定性具有解析解（Closed-form Solution），可直接通过特征协方差矩阵的统计性质进行推导。这一优良特性源于线性模型的高斯似然假设，可以绕过耗时的蒙特卡洛采样，直接计算候选样本的信息价值。本研究实现了两类基于线性预测器的主动采样策略，分别对应不同的优化目标与计算范式。

Global Greedy 策略

Global Greedy 策略的理论基础可追溯至贝叶斯实验设计（Bayesian Experimental Design）中的 D-最优准则（D-optimality）。在贝叶斯线性回归框架下，设当前已选样本的特征矩阵为 $\mathbf{X}_t$ ，候选样本为 $\mathbf{x}$ ，特征为 $\mathbf{x}$ ，可以得到如下的采集函数（具体推导过程见附录 A.2）：

$$a_{\text{Global Greedy}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_t^{-1} \mathbf{x}$$

其中

$$\mathbf{S}_t = \lambda \mathbf{I} + \mathbf{X}_t^\top \mathbf{X}_t$$

该量从几何上衡量了该样本与已有样本集的线性独立性。得分越高的样本，越能有效

地扩展已选样本的协方差矩阵，从而最大程度地缩减参数后验方差。

由于批量选择多个样本时存在组合爆炸问题，Global Greedy 策略采用序列贪心策略，即每次只选择当前最优的一个样本，更新协方差矩阵后，再选择下一个。然而，面对十万级规模的海量候选图库，对全量数据进行高频次的序列检索仍会引发显著的计算延迟。为此，本研究在该策略的工程实现中引入了动态滚动子集机制。在单轮批处理采样中，策略并非全局遍历整个候选池，而是根据一定的启发式规则，动态抽取一定规模的随机探索子集，并在该子集内部执行绝对贪心选择。

在锁定局部最优样本 $\mathbf{x}^*$ 后，系统无需重新计算全局协方差矩阵，而是利用 Sherman-Morrison 公式在 $\mathcal{O}(d^2)$ 的时间复杂度内完成逆矩阵的在线更新：

$$\mathbf{S}_{t+1}^{-1} = \mathbf{S}_t^{-1} - \frac{\mathbf{S}_t^{-1} \mathbf{x}^* (\mathbf{x}^*)^\top \mathbf{S}_t^{-1}}{1 + (\mathbf{x}^*)^\top \mathbf{S}_t^{-1} \mathbf{x}^*}$$

这一“动态子集降采样”与“逆矩阵极速更新”相结合的机制，使得单次样本选择的计算复杂度从 $\mathcal{O}(d^3)$ 大幅降至 $\mathcal{O}(d^2)$ 。配合全量 GPU 加速，该策略可轻松应对极大规模图库的实时检索需求。

均值塌陷逃逸采样策略（MCES，本研究提出）

MCES 策略是本研究针对稀疏神经元引发的模型“低拟合”与“响应坍塌”现象，原创提出的一种改进型主动采样策略。

传统的 Global Greedy 策略完全依赖于特征空间的几何正交性。然而，面对高级视觉皮层的稀疏神经元时，自然图像库中绝大多数样本对应的神经响应均为零响应。为打破这一局限，MCES 在维持特征空间全局探索的同时，创新性地引入了基于预测响应空间的“均值逃逸”机制。

MCES 策略对每个候选样本 $\mathbf{x}$ 进行特征空间与响应空间的双重指标评估：特征空间指标与 Global Greedy 相同，基于贝叶斯线性回归的后验协方差矩阵 $\mathbf{S}_t^{-1}$ ，快速计算特征空间的边际信息增益 $\mathbf{x}^\top \mathbf{S}_t^{-1} \mathbf{x}$ ；响应空间指标上引入均值塌陷因子，计算候选样本预测响应与基线均值 μ_{train} 之间的绝对距离（L1 距离），并结合自适应系数 α 构造出均值逃逸项 $\Phi(\mathbf{x}) = \exp(\alpha |y_{pred} - \mu_{train}|)$ 。

最终，MCES 策略的局部采集函数被定义为几何不确定性与均值塌陷因子的乘积：

$$a_{MCES}(\mathbf{x}) = (\mathbf{x}^\top \mathbf{S}_t^{-1} \mathbf{x}) \cdot \Phi(\mathbf{x})$$

该采集函数通过非线性融合机制，在样本选择时实现了特征空间与响应空间的动态权衡。锁定最优样本后，策略同样调用 Sherman-Morrison 公式在 $\mathcal{O}(d^2)$ 复杂度内对逆矩阵进行极速更新，并剔除已选索引，进入下一次贪心迭代。

2.2.2.5 各类主动采样策略比较总结

表 2.1 各类主动采样策略比较总结

策略	来源	采集函数核心
Random Sampling	统计学基线	均匀随机
Global Greedy	D-最优设计	特征空间不确定性最大化 $a_{\text{Global Greedy}}(x) = \mathbf{x}^T \mathbf{S}_t^{-1} \mathbf{x}$
MCES	本研究提出	几何不确定性与均值逃逸的非线性融合 $a_{\text{MCES}}(x) = (\mathbf{x}^T \mathbf{S}_t^{-1} \mathbf{x}) \cdot \Phi(x)$




图 2.4 各类主动采样策略示意图。A. Random Sampling: 作为数据效率的评估基线，从候选图像池中均匀随机地盲抽样本。B. Global Greedy: 基于 D-最优准则，在特征空间中贪心选取几何不确定性（即边际信息增益）最大的样本，并利用 Sherman-Morrison 公式完成逆矩阵的更新。C. MCES: 本研究提出的非线性融合策略。通过将特征空间的几何不确定性与预测响应的“均值偏离因子”相结合，引导预测模型打破稀疏表征下的拟合僵局，实现对特征边缘高信息量样本的精准探索。

第三章 实验结果

3.1 虚拟 AIT 稀疏神经元的生物合理性评估

在开展主动采样策略的闭环实验验证之前，首要前提是系统评估虚拟 AIT 稀疏神经元的生物学合理性。在真实的电生理实验中，猕猴 AIT 区稀疏神经元对自然图像表现出稀疏的编码特性与复杂的群体去相关性。构建的虚拟神经元群体必须在统计规律上高保真地复现这些现象。如果虚拟神经元的统计特性与真实大脑存在严重偏离，将导致后续对采样策略效率的评估失去现实指导意义。

因此，本节将摒弃单一的指标比对，从微观单神经元的放电分布（CDF）、神经元群体的特征空间拓扑（有效维度与去相关性），以及全局的宏观稀疏度分布三个层级，结合非参数检验，对生成的虚拟神经元与真实猕猴 AIT 神经元的表征特性进行多维度的客观剖析。

3.1.1 单个神经元响应分布的微观比对

首先，本研究通过排序后的神经元放电率曲线对神经元的选择性特征进行了微观维度的观察。图 3.1 A 反映了单个神经元对 1600 张测试图像的偏好程度衰减过程。

数据表明，以 DenseNet、ResNet 或 ViT 等模型作为骨干网络提取特征所生成的虚拟神经元，在分布的“头部”均能有效模拟真实 AIT 神经元（图 3.1 A 红色曲线）的高选择性，即仅在排名前 50 的极少数图像上产生显著的激活峰值。更重要的是，传统的深度神经网络由于普遍采用 ReLU，往往在拟合高度稀疏目标时表现出缺乏生物学底噪的“断崖式截断”；而本研究构建的生成架构成功克服了这一局限。观察分布的尾部可以发现，各虚拟神经元群体的响应曲线在峰值后均呈现出相对平滑的长尾衰减，与真实 AIT 区神经元的自发性基线放电形态高度重合。这一结果证实，该虚拟神经元在微观层面精确捕获了真实神经元的响应分布，为后续评估主动采样策略提供了连续且真实的梯度缓冲。

3.1.2 神经元群体的特征空间拓扑与去相关性

除了考察单神经元的微观响应特性，虚拟神经元作为一个群体，其在特征空间中是否具备足够的信息多样性同样关键。如果生成模型倾向于重复刻画偏好相同的神经元，将导致群体维度的坍塌。为此，本研究引入了有效维度与群体去相关性进行量化度量。

通过对 40 个样本进行随机子采样以计算有效维度，箱线图（图 3.1 B）显示，真实 AIT 区神经元群体的有效维度主要集中在 20 至 22 之间，说明其群体响应涵盖了丰富的正交特征子空间。所有测试模型生成的虚拟神经元群体均成功维持了这一信息复杂度，其 ED 分布区间与真实大脑高度重合。Mann-Whitney U 检验指出，各虚拟群体与真实群体在有效维度上均无统计学显著差异（ $p > 0.05$ ，标记为 ns）。

此外，从神经元间皮尔逊相关系数的核密度估计（Kernel Density Estimation, KDE）图（图 3.1 C）可以看出，真实 AIT 区神经元的相关系数紧密分布在 0 附近，形成了一个平滑的高斯峰。经过分布优化的虚拟神经元群体不仅在峰值位置上精确对齐了 0 刻度，其密度曲线的延展形态也与真实基准线几乎重叠。这客观印证了虚拟神经元内部相互独立，成功复刻了高级视觉皮层高效的去相关群体编码策略，有效避免了特征表示的冗余。




图 3.1 虚拟 AIT 稀疏神经元群体的生物合理性多维评估。 A. 单神经元微观响应分布（放电率排序曲线）。各骨干网络生成的虚拟神经元有效复现了真实 AIT 神经元（红线）的极高选择性与平滑的长尾衰减（基线放电）特征。B. 神经元群体的有效维度箱线图。基于 N=40 的随机子采样计算，Mann-Whitney U 检验表明各虚拟群体与真实大脑的有效维度分布无统计学显著差异（绿色 ns 代表 $p > 0.05$ ）。C. 群体响应去相关性的核密度估计图。各群体的神经元间皮尔逊相关系数均呈以 0 为中心的高斯分布，证实了特征空间的独立与正交性。D. 稀疏度分布的小提琴图。Mann-Whitney U 检验各虚拟群体在稀疏度中位数及整体分布形态上均与真实 AIT 高度吻合（所有 $p > 0.05$ ）。

3.1.3 稀疏度分布的宏观对齐与统计检验

最后，本节将视角提升至全局，采用 1.3.1 节所述的稀疏度指数对虚拟与真实神经元群体的宏观分布进行了对齐与检验。这是评估 AIT 区神经元模拟质量最核心的边界条件。

小提琴图（图 3.1 D）全景式地展示了由 50 个神经元构成的群体在稀疏度上的整体分布形态。实验结果表明，生成的虚拟神经元不仅在中位数上紧密贴近真实数据，其整体分布的方差、四分位距与密度轮廓也与真实 AIT 神经元达到了高度的一致性。经过严格的非参数检验（Mann-Whitney U 检验），所有人工神经网络生成的虚拟群体在宏观稀疏度上与真实猕猴数据的差异均不显著（图中标注的 p 值分别介于 0.141 至 0.654 之间，均远大于

0.05)。

这一统计学层面的高度一致性证明，本研究构建的虚拟神经元在微观、拓扑与宏观层面上，已经高保真地还原了 AIT 区“极少数神经元响应极少数图像”的核心生理规律。这确立了虚拟 AIT 稀疏神经元的生物合理性，为后续章节中客观、量化地评估各类主动采样策略在高维特征空间中的有效性，奠定了坚实的物理与数据基础。基于上述评估结果，为进一步量化不同采样策略的实战效能，后续分析将统一采用 ResNet-50 架构生成的虚拟神经元。ResNet-50 提取的特征空间已被证实与灵长类腹侧通路具有极佳的层级对应关系，能提供稳健的生物学基准。同时，本文选定 ViT 作为主动采样的核心预测器。这一选择主要基于两点深层考量：首先，ViT 的自注意力机制赋予其类生物学的全局感受野特性；更为关键的是，前期实验观测表明，在此跨架构设定下，ViT 在获取初始采样图片后的预测性能（Pearson r 的绝对数值与基线水平），逼真地复刻了真实电生理实验中利用深度神经网络预测 AIT 区神经元时所遭遇的‘低拟合度’现实困境（即两者在预测难度上展现出高度的一致性）。其次，采用“CNN 生成基准、Transformer 进行预测”的跨架构方案，能够最真实地模拟活体实验中模型架构与大脑未知底层机制之间的表征间隙，从而在这种严苛的预测条件下，验证并凸显主动采样策略的鲁棒性与泛化边界。

3.2 主动采样策略在虚拟 AIT 稀疏神经元上的表现

正如 3.1 节所述，本研究统一采用“ResNet-50 特征提取结合 ViT 网络预测”的跨架构方案，构建虚拟 AIT 稀疏神经元。为确保实验结论的统计稳健性并量化策略性能的显著性，本研究针使用了三个不同的随机种子进行闭环实验。在此高度稀疏的表征空间中，初始的随机采样导致预测模型面临严重的低拟合困境。本节将在此基准下，系统评估 Global Greedy 与 MCES 两种主动采样策略的实际效能，并深入剖析其克服拟合瓶颈的底层计算机制。

3.2.1 主动采样显著提升神经响应预测准确度

为了直观量化主动采样策略相比于 Random Sampling 策略的效能优势，本研究在多个关键迭代节点（Session 2, 6, 10, 15）绘制了 Pearson r 的对角线配对散点图（图 3.2）和关键迭代轮次的预测性能（Pearson r ）对比表（表 3.1）。图中每个散点代表一个独立的虚拟 AIT 神经元，散点位于对角线上方意味着主动采样策略在该神经元的预测性能上超越了随机采样。实验结果展现了主动采样策略在迭代过程中显著的动态优势演化：

早期探索（Session 2）：仅经过一次主动筛选，Global Greedy 与 MCES 策略的 Pearson r 即迅速分别升至 0.1475 与 0.1499，相较于同期随机采样的基准（0.1299），实现了最高约

15.4%的相对性能提升。




图 3.2 主动采样策略与随机采样的预测性能 (Pearson r) 配对对比图。 A-B. 分别展示了在四个关键迭代节点 (Session 2, 6, 10, 15), Global Greedy (A) 与 MCES (B) 两种主动采样策略相较于随机采样基线的表现。图中每个散点代表一个独立的虚拟 AIT 神经元, 横纵坐标分别对应随机采样与特定主动采样策略在测试集上的 Pearson r 值。散点位于对角线 (灰色虚线) 上方, 表明主动采样策略对该神经元的特征拟合优于随机采样。图中标注的 $p < 0.001$ 表明, 经 Wilcoxon 符号秩检验, 这两种主动采样策略在探索的各个阶段均对随机采样保持了显著的统计学优势。

持续优化 (Session 4 至 Session 10): 策略优势快速扩大, 在第 4 轮迭代时, 主动采样策略的相对提升比例攀升至峰值 (Global Greedy 策略达到 22.2%, MCES 策略达到 21.3%); 至第 6 轮和第 10 轮迭代, 尽管随机采样的基准线在庞大数据量的积累下逐渐抬升, 主动采样策略的 Pearson r 依然分别突破 0.23 与 0.27, 相对随机采样仍分别保持了约 19.8% 与 14.5% 的显著优势。

收敛末期 (Session 15): 在最终的第 15 次迭代中, 主动采样策略将 Pearson r 确立在逼近 0.30 的水平 (MCES 策略达到 0.2993, Global Greedy 策略达到 0.2972), 相较于最终的随机采样基准 (0.2682) 实现了约 11.6% 的最终性能跨越, 且 95% 置信区间全程互不重叠。

此外, 深入比对表 3.1 的数值变化, 可进一步观察到 Global Greedy 与 MCES 两种主动采样策略在不同探索阶段的细微差异: 在第一轮主动干预后 (Session 2), MCES 策略展现出微弱的领先优势 (0.1499 vs 0.1475); 然而在第 4 轮迭代时, Global Greedy 策略在数值上实现了超越 (0.2029 vs 0.2014); 但进入中后期 (Session 6 至 Session 15) 后, MCES 策略重新确立并全程维持了稳定的领先地位, 最终收敛于更高的预测水平。

这一系列跨 Session 的定量对比表明, 主动采样策略通过对高信息量样本的精准检索,

不仅能够显著缩短模型的冷启动周期，更能稳健地提升预测模型在高维特征空间中对高度稀疏神经表征的拟合上限。

表 3.1 各主动采样策略在关键迭代轮次的预测性能（Pearson r ）对比

策略	Session2	Session4	Session6	Session8	Session10	Session15
Random Sampling	0.1299	0.1661	0.1945	0.2205	0.2374	0.2682
Global Greedy	0.1475	0.2029	0.2322	0.2511	0.2677	0.2972
MCES	0.1499	0.2014	0.2330	0.2556	0.2719	0.2993

3.2.2 预测性能与绝对误差的背离：均值塌陷的启示

在 3.2.1 节的分析中，主动采样策略展现出对 Pearson r 的显著提升。然而，当同时观察绝对误差指标时，存在一个看似矛盾的现象：主动采样在 Pearson r 上显著优于随机采样，但其 RMSE 与 MAE 却始终高于后者（图 3.3 A-C）。这一评估指标的非一致性并非源于实验误差，而是揭示了稀疏编码建模中的核心困境——均值塌陷。

正如前文所述，通过随机采样训练的预测模型因陷入均值塌陷而采取趋向零值的保守预测。这种训练得到的预测模型虽能在被零响应主导的测试集上“讨巧”地获得极低的 RMSE 与 MAE，却彻底丧失了对罕见高响应刺激的预测能力。

主动采样策略通过自适应样本选择打破了这一僵局。MCES 策略的均值偏离机制引导采样轨迹远离零响应密集区，主动检索能够引发强烈放电的长尾特征样本。这种“过采样”策略迫使模型学习真正驱动神经元响应的关键几何特征，从而在测试集上成功预测响应峰值的起伏变化——这正是 Pearson r 所捕捉的“趋势相关性”。

然而，这种对稀疏表征的聚焦改变了训练数据的统计分布。模型在拟合极端放电峰值时，其预测方差增大，基线发生偏移。面对测试集中占主导地位的无响应图像时，主动采样模型产生更大的绝对数值偏差，从而推高了整体 RMSE 与 MAE。图 3.3 D 中 MAE/RMSE 比值随迭代轮次显著下降进一步印证：由于 RMSE 对大误差（如高响应峰值）更为敏感，其增速超过 MAE，表明主动模型的误差来源已从“预测平庸背景时的均匀偏差”转变为“拟合极端响应时的数值波动”。

综上所述，主动采样策略通过牺牲整体的绝对数值精度，成功打破了稀疏分布导致的表征坍塌，促使模型捕获了核心视觉特征。这一现象提示：在高级视觉皮层稀疏编码的研究中，Pearson r 是比 RMSE、MAE 更具生物学评估价值的指标——后者仅反映预测值与真实值的数值接近程度，而前者才真正衡量模型对神经元选择性响应趋势的捕捉能力。




图 3.3 主动采样策略与随机采样的多指标全局学习曲线。A. Pearson r 学习曲线。两种主动采样策略(Global Greedy, MCES)在捕捉神经元真实响应趋势上,均稳健且显著地超越了 Random Sampling 策略。B-C. 绝对误差(RMSE 与 MAE)学习曲线。受均值塌陷逃逸效应与长尾特征过采样的影响,主动采样模型因预测基线偏移,其绝对数值误差始终高于纯随机采样。D. MAE/RMSE 比值曲线。该比值随采样轮次的持续下降,进一步揭示了主动模型误差的核心来源已由背景的均匀偏差,转移至对罕见高响应峰值的拟合震荡。图中实线表示三个独立随机种子的均值,带有透明度的阴影带代表 95%置信区间。

3.2.3 MCES 策略对稀疏响应分布的探索机制

前文证实,主动采样可通过牺牲绝对误差来聚焦高响应刺激,进而打破均值塌陷。为剖析其微观机制与实现路径,本节进一步从极值命中率、神经元群体覆盖能力及响应空间探索度进行定量评估。在高度稀疏的编码体系中,采样的核心挑战在于从海量静息背景中剥离高信息量样本。定义 Top-k 响应阈值为引发目标神经元响应大小处于总体前 k% 的刺激,图 3.4 显示,在 Top-1.0%至 20.0%的动态阈值区间内,MCES 策略的极值命中率始终大幅超越 Global Greedy 与 Random Sampling 策略。这直接证明均值偏离机制有效放大了模型对长尾高响应刺激的敏感度。

除了单次采样的命中率优势,MCES 策略在群体层面的覆盖能力同样显著。以搜寻 Top-0.1%的高响应刺激为例(图 3.5),MCES 策略仅需迭代 7 轮即可率先实现全体 50 个虚拟神经元的高响应刺激完全覆盖。相比之下,Global Greedy 与 Random Sampling 策略在中后期依然遗漏了部分神经元的 Top-0.1%高响应。这表明 MCES 策略并未陷入局部易激活神经元的过采样,而是能够兼顾各个神经元。




图 3.4 各主动采样策略的极值样本命中率对比。在 Top-1.0%至 20.0%的不同响应阈值下，MCES 策略单次采样中包含高响应图像的比例均最高，展现出其对长尾特征强大的捕捉能力。图中实线表示三个独立随机种子的均值，带有透明度的阴影带代表 95%置信区间。




图 3.5 各主动采样策略的靶点覆盖率对比。图中展示了在 Top-0.1%响应阈值下，不同采样策略为全体 50 个神经元搜寻到目标刺激图像的覆盖比例随迭代轮次的变化。结果显示，MCES 策略率先达到全覆盖，表明该策略在特征探索上具备全局有效性。图中实线表示三个独立随机种子的均值，带有透明度的阴影带代表 95%置信区间。

为进一步解析 MCES 策略在响应空间的探索行为,本研究对全量候选图库进行了 PCA 降维,并绘制了各策略所选样本对应的神经元响应在二维主成分空间(PC1 与 PC2)中的核密度(KDE)等高线图(图 3.6)。由于自然图库中绝大多数样本无法激活稀疏神经元,经 PCA 中心化投影后,坐标原点及其附近区域自然构成了低响应样本的密集中心。

对比不同策略的等高线形态演变可以观察到,Random Sampling 策略的探索边界始终受限于原点附近的均值区域,难以脱离零响应背景的分布集中区。相较之下,MCES 策略的等高线分布呈现出显著的向外扩张趋势。这种响应空间上的边界扩张直观反映了均值逃逸的作用机制:策略通过主动采集位于响应特征分布外围的极值样本,有效拓展了预测模型对真实响应空间的采样范围,从而从根本上克服了由高度稀疏表征引发的模型拟合失效问题。

综上所述,MCES 策略通过均值偏离机制,在虚拟环境评估展现出三方面优势:对极值的高效捕捉、对神经元群体的均衡覆盖,以及对响应空间边界的持续扩张。然而,单一固定的采样策略难以适应动态探索需求,这促使本研究进一步引入强化学习实现自适应的策略调度。




图 3.6 各主动采样策略在特征空间中的探索边界 (KDE) 演变。基于 PCA 降维的 KDE 等高线图。随迭代轮次增加, MCES 策略的等高线包络持续向响应空间外围的极限方向扩张, 直观证实了其打破均值塌陷的空间拓扑机制。

3.3 通过强化学习优化主动采样策略

前述主动采样策略在虚拟 AIT 稀疏神经元上的实验结果表明, 固定策略难以适应稀疏

神经编码的复杂特性。不同采样方法在不同训练阶段、不同神经元群体上的效果存在差异，这提示采样策略的选择本身应当是一个自适应决策过程。为此，本研究将主动采样的采样过程建模为 MDP，引入强化学习（Reinforcement Learning, RL）训练智能体动态选择最优采样方法。

3.3.1 MDP 建模与状态空间设计

主动学习的序列采样过程可以被严密地映射为 MDP，并由标准四元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{R}, \mathcal{P})$ 刻画。具体而言，状态空间 $\mathcal{S}$ 负责提取虚拟环境的实时统计特征；动作空间 $\mathcal{A}$ 囊括了 MCES、Global Greedy 及随机采样等备选策略；奖励函数 $\mathcal{R}$ 用于量化单次动作执行后引发的 Pearson 相关系数增加；状态转移 $\mathcal{P}$ 则描述新样本加入后虚拟环境的变化轨迹。

为赋予 RL 智能体跨越不同实验环境的泛化能力，状态空间的设计刻意剥离了具体的实验配置依赖（如特定预测器架构、虚拟神经元参数或绝对采样轮次）。若状态向量过度依赖特定任务参数，智能体容易陷入过拟合，丧失对未知神经响应预测任务的泛化能力。据此原则，状态向量 $s \in \mathcal{S}$ 的构建统一采用以下通用统计特征（表 3.1）：

表 3.1 状态向量表

特征维度	符号	描述
参数不确定性	$\mathbf{S}_t = \lambda \mathbf{I} + \mathbf{X}_t^\top \mathbf{X}_t$	当前已训练样本的信息矩阵
预测不确定性	σ^2	模型在候选样本上的预测方差
采样进度	ρ	当前采样数与初始采样数的比值
性能增长趋势	Δr	近期 Pearson r 的变化率
神经元响应分布	μ_r, σ_r	群体响应的均值与标准差

3.3.2 奖励函数与折扣因子

主动采样的核心目标是提升模型对神经响应的拟合能力。因此，本研究将动作执行后的环境奖励 R_t 定义为模型在测试集上 Pearson r 的单步增长量：

$$R_t = r_t - r_{t-1}$$

其中， r_t 与 r_{t-1} 分别代表执行采样动作前后的相关系数。采用增量奖励而非绝对数值，能够更密集地反馈当前动作对 Pearson r 提升的边际贡献，有效缓解 RL 中的信用分配延迟问题。

与此相匹配，折扣因子 γ 设为较小值（如 0.5-0.7），这意味着智能体更关注近期奖励而非远期累积收益。这一设计契合主动采样的非平稳性特征：随着样本不断加入，模型的预测分布持续演化，过去状态的价值估计对远期未来的指导意义有限。小 γ 促使智能体采取“短视”但适应性高的策略，并根据当前状态快速调整采样方法，而非坚持可能已过时的

长期规划。

3.3.3 两阶段学习策略

1. 阶段一：DQN 离线预训练

为充分遍历状态-动作空间，离线预训练阶段采取纯随机策略。在每一决策步，算法从 $\mathcal{A}$ 中进行均匀随机抽样，并完整记录状态转移元组 (s_t, a_t, r_t, s_{t+1}) 。历经数十万次的随机策略迭代后，即可构建出覆盖广泛状态分布的经验回放缓冲区。

随后，使用深度 Q 网络（DQN）进行离线训练：

$$\mathcal{L}_{DQN} = \mathbb{E}_{(s,a,r,s') \sim \mathbb{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right]$$

DQN 的目标是学习状态-动作值函数的近似，通过最大化 Q 值来选择最优动作。离线训练的优势在于可以利用大量探索性数据，而不受在线交互的样本效率限制。

2. 阶段二：PPO 在线微调

DQN 训练完成后，进入近端策略优化（Proximal Policy Optimization, PPO）微调阶段。与 DQN 学习值函数不同，PPO 直接优化策略函数 $\pi(a|s)$ ，输出在给定状态下选择各动作的概率。微调采用较小的学习率，主要目的是 1. 避免大幅更新破坏 DQN 预训练获得的合理策略；2. 在 DQN 探索到的优质策略邻域内进行局部优化；3. PPO 的 clip 机制防止策略突变，保证采样行为的连续性。

PPO 的目标函数为：

$$\mathcal{L}_{PPO} = \mathbb{E}_t [\min(\rho_t(\theta) \widehat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \widehat{A}_t)]$$

其中 $\rho_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ 为重要性采样比率， $\widehat{A}_t$ 为优势函数估计， ϵ 为裁剪超参数。

3.3.4 强化学习确立主动采样的最优包络面

在完成两阶段训练后，本研究将优化的 RL 智能体应用于测试集神经元的闭环主动采样中。图 3.4 展示了 RL 元策略（紫色折线）与其他固定采样策略的全局性能对比。

实验结果表明，RL 智能体的全局表现极其精准地贴合了各阶段最优单一策略的表现，在宏观上形成了一条平滑且稳健的性能最优上包络线。这一现象对解答本研究的初始假设具有决定性的科学意义：

过去在使用被动随机采样时，稀疏神经元低的拟合率（如图中基线所示）使得我们难以界定误差的真实来源——究竟是由于有限样本未能覆盖神经元的窄带偏好（观测偏误），还是受限于预测模型的底层表征能力？本研究的结果显示，RL 智能体与多种正交的主动采样策略（如 Global Greedy 策略）最终均收敛于同一条渐近线，这一现象为上述疑问提供了客观的解答。它表明，在给定的 15 轮次采样预算下，当前的 RL 元策略能够有效规避被动采样所引发的观测偏误，最大限度地提取了当前特征空间内的有效信息。

换言之，RL 确立的这条经验上确界，不仅证明了主动采样机制相比被动随机采样具有显著的数据效率优势与稳定的性能超越，更重要的是，它为未来评估任何新型深度特征或非线性预测器，提供了一个排除了数据采样干扰的客观基准线。此外，RL 智能体能够实时评估特征空间的演化状态，实现无需人工干预的自适应策略调度，这赋予了闭环神经探测系统高的鲁棒性与工程应用价值。




图 3.7 RL 元策略与其他采样策略的全局预测性能对比。图中展示了 RL（紫色折线）与四种固定采样策略在 15 个主动学习轮次中的 Pearson r 学习曲线。实线表示三次独立随机种子的均值，半透明阴影带代表 95%置信区间。实验结果表明，RL 智能体整合各探索阶段的最优采样路径，在宏观上形成了一条平滑且稳健的最优上包络线。这证明 RL 元策略能够有效规避被动随机采样所引发的观测偏差，实现最优的数据效率，并客观地探明了当前基于线性读出层的经验上确界。

3.3.5 强化学习揭示主动采样的动态策略演化

3.2.3 节所述 MCES 策略的静态优势在 RL 的动态框架中呈现为阶段性策略分化。为进一步探究 RL 智能体是如何在底层实现最优包络面的，本研究提取了 PPO 策略网络在 15 个连续采样轮次中的动作输出概率，并绘制了策略演化的堆叠面积图（图 3.8）。该图直观地揭示了智能体在面对高度稀疏的神经响应时，自主学习到的一套从“初始极值捕获”到“特征空间扩张”再到“稳态协同采样”的自适应调度机制。

如图 3.8 所示，智能体在整个主动学习周期内展现出了精确的阶段性策略分化，其演变路径可归纳为以下三个核心阶段：

1. 初期（Session 1 - 2）：均值逃逸主导的初始拟合

在主动采样的初始阶段，预测模型处于冷启动状态，易受海量零响应样本的干扰而陷入均值塌陷的困境。此时，智能体表现出对 MCES 策略的极高偏好，其被选概率在第一轮高达约 96%。这一现象与 3.2.3 节观察到的 MCES 策略极值命中率优势高度一致：在探索极度稀疏的高维空间初期，常规的贪心或随机策略难以提供有效的信息增益；智能体倾向于利用 MCES 策略的均值偏离机制，驱动采样轨迹向特征分布的边缘延伸，以最快速度捕获罕见的神经元激活信号，从而克服初始的低拟合瓶颈。




图 3.8 RL PPO 智能体在主动采样过程中的动态策略演化。图中展示了在 15 个主动学习轮次中，智能体对三种候选采样策略的输出概率分布。不同颜色的填充区域代表各类策略在当前轮次被选中的概率 $\pi(a|s)$ ，其高度总和恒为 1.0。随采样轮次的推进，智能体展现出明显的阶段性策略分化：从初期对 MCES 策略的高度依赖（克服均值塌陷），到中前期 Global Greedy 策略权重的显著提升（特征空间的正交扩张），再到中后期 MCES 策略主导并结合 Random Sampling 策略平稳增长的多策略协同（维持极值挖掘与全局正则化的平衡）。该动态过程证实了元策略在应对稀疏神经编码复杂拓扑时的自适应优越性。

2. 中前期（Session 3 - 8）：几何正交驱动的特征空间扩张

随着初始极值特征被初步锁定，RL 智能体的策略分布发生了显著转移。Global Greedy 策略的权重迅速攀升，并在第 4 轮（Session 4）达到峰值（约 50%），与 MCES 策略的权重趋于接近。这一演化轨迹具有明确的几何优化意义：在 MCES 策略确立了若干高响应的特征锚点后，预测模型需要构建具有良好线性独立性的特征基底。Global Greedy 策略基于特征空间距离的多样性度量准则，被智能体大量调用，以促使采样在各个正交维度上均匀展开，从而有效拓宽模型对特征拓扑的全局认知边界。

3. 中后期（Session 9 - 12）：多策略稳态协同与无偏正则化

进入采样的中后期，策略分布逐渐趋于稳态，形成了一套以 MCES 策略为核心（稳定在约 55%-60%），Global Greedy 策略与 Random Sampling 策略为辅助（各占约 20%）的协同范式。具体而言，MCES 策略权重的回升确保了模型能够持续挖掘处于长尾分布的稀疏表征；Global Greedy 策略权重的保持旨在维持样本集的多样性基准。值得注意的是，Random Sampling 策略的被选概率呈现出平稳且持续的增长趋势（最终达到约 23%）。这一调度逻辑契合机器学习中的泛化与正则化原则：在采样后期引入无偏的随机探索数据，能够有效校准预测模型的全局预测基线，防止模型对特征空间边缘的极端样本产生过拟合，从而作为一种低计算成本的正则化手段，提升整体预测系统的鲁棒性。

综上所述，RL 智能体的动态策略演化充分证明，单一且固定的采样准则难以充分应对高度稀疏的编码特性。从初期的极值导向采样，到中期的特征空间正交扩张，再到后期的多策略无偏协同，这种自适应调度机制体现了强化学习在闭环神经实验中的核心价值。它不仅辅助模型逼近了预测性能的理论上限，更定量揭示了面对不同阶段的拟合瓶颈时，最优采样路径的动态演变规律。

第四章 讨论

4.1 实验结论总结

本研究针对猕猴 AIT 区稀疏编码的特性，系统性地探索并优化了大规模自然图像库下的主动采样策略。首先，本研究基于最大熵原理构建了高保真的虚拟 AIT 稀疏神经元，在不引入额外微观机制假设的前提下，客观且精确地复现了真实 AIT 群体的宏观稀疏度与去相关性统计先验。其次，针对稀疏表征引发的预测模型均值塌陷难题，本文在全流程 GPU 加速框架下，设计并提出了 MCES 策略。实验表明，该策略均值偏离，成功引导预测模型避开零响应盲区，有效挖掘了罕见的高响应特征。最后，本研究将采样过程建模为 MDP，通过 RL 训练智能体实现了采样准则的自适应调度。该元策略不仅根据特征空间的探索状态动态切换了最优采样路径，有效规避了被动随机采样的观测偏误，更在宏观上探明了当前线性读出架构的经验上确界。这一系列工作为突破高级视觉皮层的观测瓶颈提供了可能的计算框架与理论支撑。

4.2 模拟-现实差距分析

尽管主动采样系统在虚拟 AIT 稀疏神经元中展现出卓越的效能，但将其向真实的活体电生理实验 (In vivo experiments) 迁移时，必然面临不可忽视的“模拟-现实差距” (Sim-Real Gap)。这一差距的本质来源可归结为以下三点：

第一，底层编码机制的非线性动力学差异。本研究及现有的主流视觉编码模型，大多建立在“前馈特征空间映射结合线性读出”的假设之上。然而，真实的 AIT 区神经元在处理物体身份表征时，极可能涉及复杂的局部环路交互以及自上而下的反馈调节。这种高度非线性的时空动态特征与静态的线性预测模型之间存在固有的表征间隙，这可能会在一定程度上折损主动采样策略在真实大脑特征空间中的搜索效率。

第二，生物学噪声的内生复杂性与非平稳性。在活体记录中，神经元的响应不可避免地夹杂着微小眼动带来的感受野漂移、全局脑状态的涨落以及复杂的突触背景活动。这些因素导致了极高的试次间变异性。虽然本研究在虚拟环境中引入了平滑的底噪模拟，但真实的生理噪声具有高度的非平稳性和异方差性。如何在不显著增加计算负担的前提下，提升采集函数对复杂生物噪声的稳健性，是实际部署时必须跨越的障碍。

第三，RL 元策略在跨域迁移中的泛化边界尚不明确。本研究中用于动态调度采样策略的 RL 智能体，其状态空间表征与动作决策逻辑均在纯计算的虚拟环境中预训练生成。尽管该虚拟环境在宏观统计学上高度拟真，但本质上仍是对真实生物系统的高阶近似。在向真实的活体电生理环境迁移时，预测模型所面临的特征不确定性演化轨迹与单步奖励反馈流，极可能与模拟阶段产生显著的分布偏移。这种底层的环境动态差异可能导致 RL 智能

体在面对真实的、未知的稀疏响应拓扑时，做出次优的策略调度。因此，如何确保元策略在跨个体、跨生理状态下的鲁棒性，并在真实的实验闭环中通过在线反馈实现有效的数据驱动微调，是该系统真正落地前亟待验证的核心科学问题。

4.3 未来展望

4.3.1 活体闭环电生理实验的部署与闭环微调

计算神经科学模型的最终价值在于对真实生物系统的解释与预测。本研究下一阶段的核心计划，是将基于 RL 的自适应主动采样系统部署于真实的猕猴视觉电生理记录中（如图 4.1 所示）。计划依托 Neuropixels 2.0 高密度探针，在清醒猕猴执行被动注视任务时，开展大规模单神经元闭环记录。真实脑活动的反馈数据不仅将作为检验 MCES 策略实际效率的最终标准，更将直接作为 RL 智能体在线微调的真实奖励信号，从而推动元策略在真实生物噪声环境下的持续演化与自我校准。




图 4.1 活体闭环电生理实验示意图。这里的 Round 可以是跨越不同天的 session，也可以是在同一个 session 中不同的采样批次。

4.3.2 在线采样系统尝试与优化

在 AIT 区的活体实验中，本研究采用的批处理主动采样策略（Batch-mode Active

Learning) 虽然在模拟实验中展现了较高的采样效率,但在实际电生理环路中仍面临分析延迟的挑战。目前,利用 Neuropixels 探针获取的大规模 SUA 需要经过 Kilosort 等算法进行离线脉冲排序,这导致实验记录与数据分析在时间上呈现完全串行的状态(如每完成 1 小时实验需对应约 1 小时的排序时间)。在这种跨会话的模式下,虽然策略可以根据前一阶段的数据更新下一阶段的刺激包,但较长的反馈周期极大限制了整场实验的迭代频率。因此,为了进一步提高主动采样的效率,突破离线分析导致的迭代瓶颈,实现单次实验会话内的在线主动采样,未来的工程探索将集中于以下方向:

第一,采样与排序过程的时间重叠。针对目前的离线分析断层,未来的目标是缩短阶段性实验之间的“死时间”。计划开发基于 GPU 硬件加速的 Kilosort 实时处理插件,通过优化数据吞吐效能,争取在当前阶段电生理信号采集的同时,对已产生的数据进行流线化预处理与实时排序。其核心不在于改变批处理的采样性质,而是通过大幅压缩排序耗时,使实验人员能更快速地根据上一阶段的神经响应调整后续刺激策略,从而提升整场实验的采样通量。

第二,基于多层级反馈的启发式检索优化。为了在等待精确 SUA 排序结果的空窗期内依然保持采样效率,可引入多层级的启发式搜索机制。在离线 SUA 排序尚未完成时,系统可先利用计算成本极低、无需复杂排序的多神经元活动(Multi-unit activity, MUA)信号对大规模图库进行初步筛选。MUA 虽无法提供单神经元级别的精确调谐特征,但能反映当前记录位点宏观的表征倾向。通过 MUA 进行“预采样”以锁定大致的高响应特征区间,待 SUA 精确结果产出后再进行针对性的“精细补样”,这种双轨并行的策略将最大限度利用实验窗口。

第三,面向闭环集成的系统级封装。未来的工作还将致力于将本研究开发的图像检索与 RL 采样逻辑集成至主流的电生理采集管线中。通过利用显存共享(Zero-copy)等技术,减少大规模图像特征在 GPU 上的加载开销,实现在分段式实验框架下更高效的主动采样闭环,为在复杂生物噪声环境下精确标定 AIT 区的神经表征特性提供工程支持。

4.3.3 检索式采样与生成式采样的融合

目前本研究的主动采样主要依托于对大规模自然图库的检索。虽然检索法能够保持图像的自然统计特性,但受限于预设图库的特征边界,难以探索神经元潜在的极端偏好空间。

未来的研究方向将考虑引入生成式模型(如 GAN 或 Diffusion Model)来优化采样序列。具体而言,在异步批处理的框架下,策略不仅可以从现有图库中检索刺激,还可以根据前一阶段标定出的神经元偏好特征,利用生成模型定向合成出一批全新的、具有更强特征强度的候选图片。这种“检索-合成”混合的主动采样范式,有望突破自然图像库的分布限制,在更高维、更连续的特征空间中精确定位 AIT 神经元的响应极限。

参考文献

1. Felleman DJ, Van Essen DC. Distributed hierarchical processing in the primate cerebral cortex. *Cereb Cortex* **1**, 1-47 (1991).
2. Kandel, E.R., Schwartz, J.H., Jessell, T.M., Siegelbaum, S., and Hudspeth, A.J. (2013). Principles of neural science, 5th edn (McGraw-hill New York).
3. Hubel, D.H., and Wiesel, T.N. Receptive fields and functional architecture of monkey striate cortex. *J Physiol* **195**, 215-243 (1968).
4. Mishkin M, Ungerleider LG. Contribution of striate inputs to the visuospatial functions of parieto-preoccipital cortex in monkeys. *Behav Brain Res* **6**, 57-77 (1982).
5. Kandel, E.R., Schwartz, J.H., Jessell, T.M., Siegelbaum, S., and Hudspeth, A.J. (2021). Principles of neural science, 6th edn (McGraw-hill New York).
6. Pasupathy, A., Connor, C. Population coding of shape in area V4. *Nat Neurosci* **5**, 1332–1338 (2002).
7. Wang, T., Lee, T.S., Yao, H. *et al*. Large-scale calcium imaging reveals a systematic V4 map for encoding natural scenes. *Nat Commun* **15**, 6401 (2024).
8. Tanaka K. Inferotemporal cortex and object vision. *Annu Rev Neurosci* **19**, 109-139 (1996).
9. Tsao DY, Freiwald WA, Tootell RB, Livingstone MS. A cortical region consisting entirely of face-selective cells. *Science* **311**, 670-674 (2006).
10. Kobatake E, Tanaka K. Neuronal selectivities to complex object features in the ventral visual pathway of the macaque cerebral cortex. *J Neurophysiol* **71**, 856-867 (1994).
11. Freiwald, W.A., Tsao, D.Y., and Livingstone, M.S. A face feature space in the macaque temporal lobe. *Nat Neurosci* **12**, 1187-1196 (2009).
12. D.L.K. Yamins, H. Hong, C.F. Cadieu, E.A. Solomon, D. Seibert. *et al*. Performance-optimized hierarchical models predict neural responses in higher visual cortex, *Proc. Natl. Acad. Sci. U.S.A* **111**, 8619-8624 (2014).
13. Yamins, D., DiCarlo, J. Using goal-driven deep learning models to understand sensory cortex. *Nat Neurosci* **19**, 356–365 (2016).
14. Kar, K., Kubilius, J., Schmidt, K. *et al*. Evidence that recurrent circuits are critical to the ventral stream’s execution of core object recognition behavior. *Nat Neurosci* **22**, 974–983 (2019).
15. Zhuang C, Yan S, Nayebi A, *et al*. Unsupervised neural network models of the ventral visual stream. *Proc Natl Acad Sci U S A* **118**, e2014196118 (2021).
16. Doerig, A., Sommers, R.P., Seeliger, K., Richards, B., Ismael. *et al*. The neuroconnectionist research programme. *Nature Reviews Neuroscience* **24**, 431-450 (2023).
17. Op De Beeck H, Vogels R. Spatial sensitivity of macaque inferior temporal neurons. *J Comp Neurol* **426**, 505-518 (2000).
18. Peter Földiák. Stimulus optimisation in primary visual cortex. *Neurocomputing* **38–40**, 1217-1222 (2001).
19. Jeremy Lewi, Robert Butera, Liam Paninski. Sequential Optimal Design of Neurophysiology Experiments. *Neural Comput* **21**, 619–687 (2009).
20. DiMattina, C. & Zhang, K. Adaptive stimulus optimization for sensory systems neuroscience. *Front. Neural Circuits* **7**, 101 (2013).

21. Cowley, B. R. *et al.* Adaptive stimulus selection for optimizing neural population responses. *Adv. Neural Inf. Process. Syst.* **35**, 1-14 (2022).
22. Cowley, B.R., Stan, P.L., Pillow, J.W. *et al.* Compact deep neural network models of the visual cortex. *Nature* **652**, 947–954 (2026).
23. Cowley, B. R. & Pillow, J. W. High-contrast gaudy images improve the training of deep neural network models of visual cortex. *Adv. Neural Inf. Process. Syst.* **33**, 1-12 (2020).
24. Schneidman, E., Berry, M., Segev, R. *et al.* Weak pairwise correlations imply strongly correlated network states in a neural population. *Nature* **440**, 1007–1012 (2006).
25. Gal, Yarin and Ghahramani, Zoubin. Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning. *Proceedings of The 33rd International Conference on Machine Learning* **48**, 1050-1059 (2016).
26. Jordan T. Ash and Chicheng Zhang and Akshay Krishnamurthy and John Langford and Alekh Agarwal. Deep Batch Active Learning by Diverse, Uncertain Gradient Lower Bounds. *arXiv*, 1906.03671 (2020).

附录 A

附录 1 部分数学公式说明

1. 稀疏度 (Lifetime Sparseness) 定义

对于单个神经元，其稀疏度 S 定义为：

$$S = 1 - \frac{(\sum_{i=1}^n r_i / n)^2}{\sum_{i=1}^n (r_i^2 / n)}$$

其中 n 为刺激集图像总数， r_i 为神经元对第 i 张图像的响应放电率。 S 越大代表反应越稀疏。

2. 群体有效维度 (Effective Dimension) 定义

有效维度 ED 用于刻画 N 个神经元群体表征的独立性与信息承载量：

$$ED = \frac{(\sum_{i=1}^N \lambda_i)^2}{\sum_{i=1}^N \lambda_i^2}$$

其中 λ_i 为群体响应协方差矩阵的特征值。在对比实验中，随机抽取 40 个神经元并重复计算，以获取有效维度的统计分布。

附录 2

3. Global Greedy 策略采集函数的部分推导

在贝叶斯线性回归框架下，我们首先建立如下的概率模型：

先验分布：假设模型参数 $\mathbf{w} \in \mathbb{R}^d$ 服从高斯先验

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \lambda^{-1} \mathbf{I})$$

其中 λ 为正则化系数，控制先验的精度。

似然函数：给定数据集 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，观测噪声服从高斯分布

$$p(y_i | \mathbf{x}_i, \mathbf{w}) = \mathcal{N}(\mathbf{w}^\top \mathbf{x}_i, \sigma^2)$$

写为矩阵形式，设 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 为特征矩阵， $\mathbf{y} \in \mathbb{R}^n$ 为响应向量，则

$$p(\mathbf{y} | \mathbf{X}, \mathbf{w}) = \mathcal{N}(\mathbf{X}\mathbf{w}, \sigma^2 \mathbf{I})$$

后验分布：根据贝叶斯定理，参数的后验分布为

$$p(\mathbf{w} | \mathcal{D}) \propto p(\mathbf{y} | \mathbf{X}, \mathbf{w}) \cdot p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \boldsymbol{\mu}_n, \boldsymbol{\Sigma}_n)$$

其中后验均值和协方差矩阵为：

$$\begin{aligned} \boldsymbol{\mu}_n &= \sigma^{-2} \boldsymbol{\Sigma}_n \mathbf{X}^\top \mathbf{y} \\ \boldsymbol{\Sigma}_n &= (\lambda \mathbf{I} + \sigma^{-2} \mathbf{X}^\top \mathbf{X})^{-1} \end{aligned}$$

在主动采样框架下，我们的目标是选择新样本 $\mathbf{x}$ 使得加入该样本后，模型参数的后验不确定性最小化。后验不确定性可由协方差矩阵 $\boldsymbol{\Sigma}_n$ 的某种标量度量来刻画，常用的选择包括：

A-最优性：最小化 $\text{tr}(\boldsymbol{\Sigma}_n)$ （后验方差之和）

D-最优性：最大化 $|\boldsymbol{\Sigma}_n^{-1}|$ （信息矩阵的行列式）

E-最优性：最大化 $\lambda_{\min}(\Sigma_n^{-1})$ （最小化特征值）

Global Greedy 策略采用 D-最优性准则，等价于最大化信息矩阵的行列式。设当前已选样本的特征矩阵为 $\mathbf{X}_t$ ，信息矩阵为：

$$\mathbf{S}_t = \lambda \mathbf{I} + \mathbf{X}_t^\top \mathbf{X}_t$$

考虑候选样本 $\mathbf{x}$ ，加入后的信息矩阵为：

$$\mathbf{S}_{t+1} = \mathbf{S}_t + \mathbf{x}\mathbf{x}^\top$$

根据矩阵行列式引理：

$$|\mathbf{S}_{t+1}| = |\mathbf{S}_t| \cdot (1 + \mathbf{x}^\top \mathbf{S}_t^{-1} \mathbf{x})$$

因此，最大化 $|\mathbf{S}_{t+1}|$ 等价于最大化采集函数：

$$a_{\text{Global Greedy}}(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_t^{-1} \mathbf{x}$$